

Exercício Prático 1

Modelo de Classificação xG

Neste exercício prático, proponho-me apresentar um novo modelo, com o objetivo de melhorar a *performance* do modelo fornecido como *Baseline*, no que a um problema de classificação de um *Dataset* de remates diz respeito.

O modelo fornecido como exemplo, considerou as seguintes 21 *features*:

- *x*;
- *y*;
- *Deflection*;
- *Assisted*;
- *Intentional assist*;
- *Set piece*;
- *From corner*;
- *Individual Play*;
- *Free kick*;
- *Penalty*;
- *Fast break*;
- *Regular play*;
- *Box-centre*;
- *Box-left*;
- *Box-right*;
- *Small box-right*;
- *Small box-left*;
- *Small box-centre*;
- *Box-deep right*;
- *Box-deep left*;
- *Out of box-centre*.

Usando um conjunto de treino de 2812 observações e um conjunto de teste de 704 observações, o modelo permitiu obter as seguintes performances, de acordo com as métricas *Precision*, *Recall*, *F1-Score* e *Accuracy*, e com os algoritmos *Logistic Regression*, *K-Nearest Neighbors (KNN)* e *Extreme Gradient Boosting (XGboost)*.

	Precision	Recall	F1-Score	Accuracy	AUC Score
Logistic Regression	0,89	0,35	0,50	0,84	0,67
KNN	0,63	0,43	0,51	0,80	0,68
XGboost	0,94	0,19	0,32	0,80	0,68


Interpretando os resultados obtidos e recorrendo à matriz de confusão que se segue, podemos verificar que tomando, como exemplo, o algoritmo *Logistic Regression*:

$$Precision = \frac{TP}{TP + FP} = \frac{59}{59 + 7} \approx 0,89$$


$$Recall = \frac{TP}{TP + FN} = \frac{59}{59 + 109} \approx 0,35$$

$$F1 - score = \frac{2 \times TP}{2 \times TP + FP + FN} = \frac{2 \times 59}{2 \times 59 + 7 + 109} \approx 0,50$$


$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{59 + 529}{59 + 529 + 109 + 7} \approx 0,84$$



Analisando os resultados obtidos, salta à vista o baixo valor de *Recall*. Apesar de o modelo ter a capacidade de classificar corretamente a maior parte dos remates classificados como golo, o mesmo não é capaz de classificar como golo a maior parte dos remates que foram efetivamente golo. O novo modelo deverá ter em consideração esta incapacidade. Nota para o valor relativamente baixo de *F1-score* uma vez que, sendo uma média harmónica entre *Precision* e *Recall*, “sofre” do baixo valor de *Recall*. Ainda assim, a *Accuracy* é relativamente elevada.



Como o objetivo de melhorar o modelo *Baseline* comecei por procurar introduzir novas *features* que pudessem, de alguma forma, ser mais informativas. A ideia foi, como base nas *features* de posição do remate x e y , criar as *features* distância do remate à baliza e ângulo do remate. Para tal, comecei por analisar as *features* x e y e verifiquei tinham alguns *outliers*/valores incorretos. Como se pode verificar no diagrama de dispersão seguinte, há várias observações no Dataset que têm valores de x muito pequenos e que estão classificados como golo. Estes valores não podem ser reais, pelo que devem ser retirados do Dataset. Experimentei vários valores para o filtro a considerar ($x \geq 33$, $x \geq 50$ e $x \geq 66$), tendo optado apenas pelos remates no meio-campo adversário, por ter sido aquele que produziu melhores resultados.




Assim sendo, o nosso Dataset ficou com 2785 observações no conjunto de treino e 697 no conjunto de teste.

Master em *Big Data* Aplicado ao Futebol

Módulo 6: *Machine Learning* – Introdução às técnicas e modelos aplicáveis

De seguida, introduzi dois novos features, *Distance* e *Angle*, definidos da seguinte forma:

- $distance = \sqrt{x^2 + c^2}$
- $angle = \frac{\pi}{2} - \tan^{-1}\left(\frac{c - \frac{7,32}{2}}{x}\right) - \tan^{-1}\left(\frac{x}{c + \frac{7,32}{2}}\right)$




onde x representa a abcissa (simétrica) do remate, convertida para a escala de 105 metros de comprimento de um campo de futebol e c representa a distância entre a posição do remate e a projeção da sua ordenada no centro do campo, convertida para a escala de 68 metros de largura de um campo de futebol.

```
df["X"] = (100 - df['x']) * 105/100 # Inverte a abcissa do remate e calcula o valor proporcional num campo de 105 metros de comprimento
df["Y"] = df['y'] * 68/100 # Calcula o valor proporcional da ordenada do remate num campo de 68 metros de largura
df["C"] = abs(df['y'] - 50) * 68/100 # Calcula o valor da proporcional num campo de 68 metros de largura da distância da ordenada do remate e a ordenada central no campo

#calcular a distancia e o ângulo de remate
df["Distance"] = np.sqrt(df["X"]**2 + df["C"]**2)
df["Angle"] = np.where(np.pi/2 - np.arctan((df["C"]-7.32/2)/df["X"]) - np.arctan(df["X"]/(df["C"]+7.32/2)) > 0,
    np.pi/2 - np.arctan((df["C"]-7.32/2)/df["X"]) - np.arctan(df["X"]/(df["C"]+7.32/2)),
    np.pi/2 - np.arctan((df["C"]-7.32/2)/df["X"]) - np.arctan(df["X"]/(df["C"]+7.32/2)) + np.pi)
```

Ao introduzir estes novos features, pude verificar que melhoram o modelo, quando comparado com a modelo contendo os features x e y e que mesmo mantendo estes últimos juntamente com os dois introduzidos, não conseguimos obter melhores resultados. Analisando o mapa de correlações, podemos verificar que as variáveis x e *distance* têm muita correlação muito elevada (em valor absoluto) e também que a variável y está muito pouco correlacionada com o nosso *target*. Assim sendo, optei por manter apenas as novas variáveis *distance* e *angle*. Nota para o facto de as variáveis *distance* e *angle*, elas próprias, também terem uma correlação elevada, algo que será mais tarde tido em consideração, na altura da escolha dos *features* finais para o nosso modelo.



Master em *Big Data* Aplicado ao Futebol

Módulo 6: *Machine Learning* – Introdução às técnicas e modelos aplicáveis


Depois de analisar as variáveis quantitativas passei, em seguida, para o estudo das variáveis categóricas.

Em primeiro lugar, tive em consideração, juntamente com as variáveis *Big Chance* e *Deflection*, as variáveis de jogada:

- Assisted
- From corner
- Penalty
- Intentional assist
- Individual play
- Fast Break
- Set piece
- Free kick
- Regular Play

Para estas, depois de substituir '-' por 'não', de preencher os valores vazios também com 'não' e de verificar que, em função de as variáveis *Set piece*, *From corner*, *Individual Play*, *Free kick* e *Regular play* serem mutuamente exclusivas, não poderem ter valores todos iguais, procedeu-se à análise gráfica de cada uma delas, em função do *target*. Pode-se verificar que a variável *Big Chance* parece ter, claramente, um elevado poder preditivo, em função da diferença na proporção de golos verificados em função de o remate ter sido classificado como *Big Chance* ou não. Introduzir ou não esta variável foi ponderado, uma vez que sendo a mesma manualmente introduzida pelos codificadores e verificado depois de saber o resultado do remate, pode sofrer do chamado *Outcome Bias*. Ainda assim, a mesma foi adicionada ao nosso modelo (**modelo 1**).

Note-se que, para todos os modelos considerados, foi efetuado um *Minmaxscaler* para as variáveis *distance* e *angle* e que todas as variáveis categóricas foram convertidas em 1 e 0.




Procedi da mesma forma para as restantes variáveis categóricas, dentro deste grupo variáveis de jogada.


Conseguimos verificar, pela análise dos gráficos seguintes que, há algumas variáveis que parecem ter poder preditivo, como as variáveis *Deflection*, *Free Kick*, *Penalty* ou *Fast Break*, enquanto que outras poderão não ajudar o modelo a melhorar a sua *performance*. Todas as variáveis foram adicionadas ao modelo anterior (**modelo 2**).

Master em *Big Data* Aplicado ao Futebol

Módulo 6: *Machine Learning* – Introdução às técnicas e modelos aplicáveis



Finalmente, foi realizada uma análise à *feature importance*, no sentido de verificar quais das variáveis introduzidas têm maior poder preditivo. Verificou-se que as variáveis *Assisted*, *Intentional assist*, *set piece*, *from corner* e *individual play* não têm grande poder preditivo. As mesmas foram retiradas do modelo anterior (**modelo 3**).



Comparando os três modelos analisados podemos tirar as seguintes conclusões. O **modelo 1**, contendo a variável *Big Chance*, para além das variáveis *Distance* e *Angle*, consegue melhorar muito o modelo Baseline em todas as métricas, à exceção da Precision, em que há uma diminuição de 5 pontos percentuais. No entanto, em todas as restantes métricas, as melhorias são assinaláveis, o que mostra a capacidade do modelo em classificar como golo os remates que foram efetivamente golo. O **modelo 2** é mais complexo, em função de ter muitas mais variáveis e melhora a performance do modelo 1. No entanto, depois de efetuar a *feature importance*, conseguimos ter um **modelo 3**, menos complexo que o modelo 2 e que não perde em termos de performance.

	Precision	Recall	F1-Score	Accuracy	AUC Score
Modelo 1	0,84	0,70	0,76	0,90	0,83
Modelo 2	0,85	0,75	0,80	0,91	0,86
Modelo 3	0,85	0,75	0,80	0,91	0,86


Master em *Big Data* Aplicado ao Futebol

Módulo 6: *Machine Learning* – Introdução às técnicas e modelos aplicáveis

Em seguida, passou-se à análise das variáveis do tipo de remate

- Right footed
- Left Footed
- Head
- Swerve Right
- Swerve Left
- Other body part

Foi feita a análise já efetuada no *notebook* de exemplo, substituindo ‘-’ por ‘não’, de preencher os valores vazios também com ‘não’. Não consideramos as variáveis *Swerve right* e *Swerve left* e, em função das restantes quatro serem mutuamente exclusivas, procurou-se as linhas que eram todas iguais e transformou-se o valor de *Other body part* para ‘sim’ no sentido de que, se um remate não foi realizado com o pé direito, com o pé esquerdo nem com a cabeça, então terá sido realizado com outra parte do corpo. Analisando os gráficos destas quatro variáveis relativos à variável *golo*, não parece haver margem para melhorar o nosso modelo, já com uma boa *performance*. De qualquer forma, as mesmas foram adicionadas ao modelo 3 e verificou-se que, de facto, o novo **modelo 4** não melhorou a performance do anterior.




Finalmente, foi efetuada a análise das variáveis de posição. O tratamento dos casos anteriores foi novamente realizado e verificou-se que não há observações com todos os valores iguais, o que seria impossível em função de estas variáveis serem mutuamente exclusivas.

- Box-centre
- Box-left
- Box-right
- Small box-right
- Small box-left
- Small box-center
- Box-deep right
- Box-deep left
- Out of box-centre


Analisando os gráficos seguintes podemos verificar que há margem para melhorar o nosso modelo. Todas as variáveis foram adicionadas ao modelo 3 e verificou-se a performance do novo **modelo 5**.

Master em *Big Data* Aplicado ao Futebol

Módulo 6: *Machine Learning* – Introdução às técnicas e modelos aplicáveis



Em seguida, de forma a verificar se todas as variáveis em causa seriam relevantes para o modelo, foi efetuada nova *feature importance* tendo-se concluído que variável *angle* parece ser a menos preditiva. De facto, ao introduzir variáveis que realçam a zona do campo de onde foi efetuado o remate, acaba por tornar dispensável a variável *angle*. Este novo **modelo 6**, sem a variável *angle* foi também testado.



Analisando os resultados obtidos, conseguimos verificar que as variáveis de posição melhoram a performance do modelo e, deixando cair a variável *angle* conseguimos atingir um nível de *Precision* que superam o resultado do modelo *Baseline*.

	Precision	Recall	F1-Score	Accuracy	AUC Score
Modelo 3	0,85	0,75	0,80	0,91	0,86
Modelo 5	0,90	0,75	0,82	0,93	0,86
Modelo 6	0,91	0,75	0,82	0,93	0,86

Assim sendo, optamos por restar com as seguintes *features*:

- *Distance*
- *Free kick*
- *Regular play*
- *Box-right*
- *Small box-center*
- *Out of box-centre*
- *Big Chance*
- *Penalty*
- *Box-centre*
- *Small box-right*
- *Box-deep right*
- *Deflection*
- *Fast break*
- *Box-left*
- *Small box-left*
- *Box-deep left*

Estando seleccionadas os *features* para o nosso modelo foi, em seguida, escolhido o algoritmo a considerar, tendo sido considerados o já testado Logistic Regression, para além dos já referidos KNN e XGboost. Os resultados obtidos permitem concluir que o melhor algoritmo a considerar é Logistic Regression.

	Precision	Recall	F1-Score	Accuracy	AUC Score
Logistic Regression	0,91	0,75	0,82	0,93	0,86
KNN	0,83	0,67	0,74	0,89	0,81
XGboost	0,85	0,75	0,80	0,91	0,81

Em jeito de conclusão, com este trabalho procurou-se encontrar o melhor modelo possível para poder classificar um remate como golo ou não, com base na respetiva probabilidade. Foram criados novos *features* e verificou-se quais dos considerados seriam de escolher, recorrendo a um EDA e a uma conveniente limpeza de dados. As escolhidas foram aqueles mais preditivas, tendo em conta o sua *feature importance*. Foram também comparados diversos algoritmos, tendo-se concluído que Logistic Regression, seria o melhor modelo.

